

3.1 ① Бинарный линейный классификатор

$$a(x) = \begin{cases} 1, & \text{если } f(x) > 0 \\ -1, & \text{если } f(x) < 0 \end{cases}$$

$$f = \langle w, x \rangle$$

② Отсечь алгоритма  $a(x) = \text{sign} f(x)$  на объекте  $x$ : най-ся

$$M_i = y_i f(x_i) \quad M_i \leq 0 \Leftrightarrow y_i \neq a(x_i) \\ M_i > 0 \Leftrightarrow y_i = a(x_i)$$

③  $\text{sign}(\langle w, x \rangle - w_0) \rightarrow \text{sign}(\langle w, x \rangle)$

надо добавить к векторам  $y$   $x$   $(-1)$

④  ~~$Q(w) = \sum_{i=1}^l (M_i(w) < 0)$~~

~~наименьший~~  $\tilde{Q}(w) = \sum_{i=1}^l L(M_i(w)) \rightarrow \min_w$   
ф-ция потерь

Должен принимать наименьшее (0).

⑤  $\tilde{Q}(w) = \sum_{i=1}^l (M_i(w) < 0)$

~~Если взять  $w = x$ , то~~

~~$a(x) = \text{sign}(\langle x, x \rangle) = \text{sign}|x|^2 > 0$~~

~~Всегда~~



Возьмем  $w = 0$  - (ну все нули)

Тогда  $a(x) = \text{sign}(\langle x, 0 \rangle) = \text{sign } 0 = 0$

$\Rightarrow M_i(w) = 0 \Rightarrow \tilde{Q}(w) = 0$  - это мин

$$(6) \quad \tilde{Q}(w) = \sum_{i=1}^I \log_2(1 + e^{-M_i})$$

(7) Функция потерь - функция от  
у настоящего и предсказанных.  
Нужно, чтобы понимать качество  
модели. Обычно должна  
уменьшаться при приросте  
каких-то параметров друг к другу.

(8) Непладкая ф-ция потерь. В  
данном случае с лин регрес.  
 $\text{sign}(M)$  - неплладкая ф-ция потерь

(9) Регуляризация - техника, направленная  
на ограничение коэффициентов,  
чтобы избежать переобучения.

$$l_1: \sum_{k=1}^m |w_k| \leq T \quad l_2: \sum_{k=1}^m w_k^2 \leq T$$

(10) Переобучение уменьшает  
обобщающую способность алгор.  
Регуляризация уменьш. переобучение,  
следовательно, увеличивает  
обобщ. способность.

(11) Если мы в остром минимуме,  
то скорее всего мы переобучились

(12) Делает более простой.



(13) большее значение функционал  
аппрокс. раск. будет приме-  
маз при наличии регуляризац.

~~(14)~~ Т.к. функционал будет  
проше, то без регуляриз.  
минимумов.

(14) Если регуляризация оправды-  
вает себя, значит, добавление  
к предсказаниям, то без функцио-  
нал меньше. Итого, большее  
значение без регуляризации.

(15) Accuracy =  $\frac{tp + fp}{N}$   $N = tp + fp + tn + fn$   
Precision =  $\frac{tp}{tp + fp}$


Recall =  $\frac{tp}{tp + fn}$

(16) Roc - кривая для бинар классиф.  
это зависимость TPR от FPR

AUC - площадь под ROC-кривой

(17) ~~TPR = Recall~~  $FRR = \frac{fp}{fp + tn}$   
 $TPR = \frac{tp}{tp + fn}$

Нужно посчитать  $tp, tn, fp, fn$   
и далее построить по ним  
~~кривую~~ FPR и TPR и  
построить по ним:





3.2  $P(x, y | \omega)$  - вероятностная модель данных

$p(\omega)$  - априорное распределение

$P(X^L, \omega) = P(X^L | \omega) p(\omega)$  - правдоподоб

логарифм правдоподоб:

$$L(X^L, \omega) = \sum_{i=1}^L \ln p(x_i, y_i | \omega) + \ln p(\omega)$$

Т.е.  $\ln p(\omega)$  можно рассматривать как регуляризатор

$l_2$ :  $p(\omega)$  -  $n$ -мерное гауссовское

$$-\ln p(\omega, \sigma) = \frac{1}{2\sigma} \|\omega\|^2 + \text{const}(\omega)$$

$l_1$ :  $p(\omega)$  -  $n$ -мерное Лапласа

$$-\ln p(\omega, c) = \frac{1}{c} \sum_{j=1}^n |\omega_j| + \text{const}(\omega)$$

3.3  $\min_{i=1 \dots L} y_i (\langle \omega, x_i \rangle - \omega_0) = 1$

$$\begin{aligned} \langle (x_+ - x_-), \frac{\omega}{\|\omega\|} \rangle &= \frac{\langle \omega, x_+ \rangle - \langle \omega, x_- \rangle}{\|\omega\|} = \\ &= \frac{(\omega_0 + 1) - (\omega_0 - 1)}{\|\omega\|} = \frac{2}{\|\omega\|} = \frac{2}{\langle \omega, \omega \rangle} \end{aligned}$$

Услов:

$$\begin{aligned} &\langle \omega, \omega \rangle \rightarrow \min \\ &y_i (\langle \omega, x_i \rangle - \omega_0) \geq 1 \end{aligned}$$



Если выборка линейно separable!

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + c \sum_{i=1}^l \varepsilon_i \rightarrow \min_{w, w_0, \varepsilon} \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \varepsilon_i \quad i=1 \dots l \\ \varepsilon_i \geq 0 \quad i=1 \dots l \end{cases}$$

$$\varepsilon_i \geq 0 \quad \varepsilon_i \geq 1 - M_i \quad \sum_{i=1}^l \varepsilon_i \rightarrow \min$$

$$\Rightarrow \varepsilon_i = \max\{0, 1 - M_i\} = (1 - M_i)_+$$

$$\text{Итого: } Q(w, w_0) = \sum_{i=1}^l (1 - M_i(w, w_0))_+ + \frac{1}{2c} \|w\|^2 \rightarrow \min_{w, w_0}$$

$$\boxed{3.4} \quad x_1^2 + 2x_2^2 = 3$$

$$x_1' = x_1^2 \quad x_2' = x_2^2 \quad \psi \quad w' = w$$

$$\text{Тогда разд. пов. фз} \quad x_1' + 2x_2' - 3 = 0$$

Размерность принимающего  
пр-ва - 2.

$$\text{Ядро: } \langle \psi(x), \psi(w) \rangle$$

$$\boxed{3.6} \quad \text{Смотри } \boxed{3.1} \quad 15, 16, 17$$



$$(3.5) \begin{cases} \sum_{i=1}^l L(M_i) \rightarrow \min & (1) \quad (4) \\ \sum_{k=1}^m |\omega_k| \leq b \end{cases}$$

$$(3) \begin{cases} \sum_{i=1}^l L(M_i) + \lambda \sum_{k=1}^m |\omega_k| \rightarrow \min_{\omega, \lambda \geq 0} \end{cases}$$

$$L(\omega, \lambda) = \sum L(M_i) + \lambda (\sum |\omega_k| - b)$$

По Т. Куна - Таккера

где существование решения  $\hat{\omega}$  в (3) необходимо и достаточно

$$\exists \lambda \geq 0: \begin{cases} 1. L(\hat{\omega}, \lambda) = \min_{\omega} L(\omega, \lambda) \\ 2. \lambda (\sum |\hat{\omega}_k| - b) = 0 \end{cases}$$

При  $b > 0$   $\exists \hat{\omega} \sum |\hat{\omega}_k| < b$ , т.е. условие  
Слейтера выполняется  
(где достаточно)

$$(4) \Leftrightarrow 1$$

Осталось условие 2.

$$2 \Leftrightarrow \lambda = 0 \text{ или } \sum |\omega_k| = b$$

Если  $\lambda = 0$ , то  $\hat{\omega}$  в  $\sum |\hat{\omega}_k| < b$

$\Rightarrow \sum |\omega_k| \leq b$  - выполнено

и  $(3) \Leftrightarrow (4)$  при  $\lambda = 0$



Если  $\lambda > 0$ , то  $\sum |\omega_k| = 6$

выполнения того условия  
можно добиться в (4) обес-  
печив в качестве поряд-  
ксов оптимальной в (4).